Nama: Muhammad Fauzan Aldi

NIM : 1103210049

Kelas: TK-45-GAB04

LAPORAN UTS MACHINE LEARNING

1. Regression Model

Buat Explanatory Data Analysis dan Data Visualization dari dataset RegresiUTSTelkom.csv

```
UTS_MachineLearning_Muhammad Fauzan Aldi_1103210049.ipynb
File Edit View Insert Runtime Tools Help All changes saved
Code + Text
import numpy as np
     import pandas as pd
    import matplotlib.pyplot as plt
    import seaborn as sns
     import seaborn as sns
     import plotly.graph_objects as go
     from sklearn.pipeline import Pipeline # Changed 'pipeline' to 'Pipeline
     from sklearn.preprocessing import PolynomialFeatures, StandardScaler
     from sklearn.tree import DecisionTreeRegressor
     from sklearn.neighbors import KNeighborsRegressor
     from xgboost import XGBRegressor
     from sklearn.model_selection import GridSearchCV, train_test_split
     from sklearn.metrics import mean_squared_error, r2_score
[42] df = pd.read_csv('/content/RegresiUTSTelkom.csv')
```

Kode ini mengimpor berbagai pustaka dan modul yang sering digunakan dalam analisis data dan machine learning (Data Manipulation & Visualization, Machine Learning Models, Model Evaluation & Optimization).

df = pd.read_csv('RegresiUTSTelkom.csv') digunakan untuk membaca file CSV bernama RegresiUTSTelkom.csv dan memuatnya ke dalam sebuah DataFrame df menggunakan pustaka pandas.

```
print("Dataset info:")
print(df.info())
 print(df.info())
print("\nSummary Statistic:")
print(df.describe())
  print("\nMissing values:
print(df.isnull().sum())
                                                                                                                                                                               49.94357
126787.000000
43.358845
6.091330
4.418500
39.932120
44.206200
47.844820
59.579700
                                                                                                                                 mean
std
min
25%
50%
75%
max
             951.0896
698.11428
                                                                                                                                                           -1.817593
7.919477
                                        126786 non-null
                                                                                                                        0
                                                                                                                                 mean
std
min
25%
50%
75%
max
                                                                                                                                                                                                                                1.11144
                                                                                                                                                                                 15, 37344
126786,000000
38,461144
94,274230
-1495,872230
-4,356750
33,432295
77,461388
                                                                                                                                                                                                                              6.000000
0.314231
                                                                                                                                  mear
std
min
25%
50%
75%
max
                                                                                                                                                                                                                        84.279100
5289.111380
                                                                                                                 [8 rows x 91 columns]
                                                                                                                   Missing values:
                                                                                                                   49.94357
                                                                                                                   21.47114
                                                                                                                   73.0775
                                                                                                                    -1.82223
                                                                                                                     -27.46348
                                                                                                                  Length: 91, dtype: int64
```

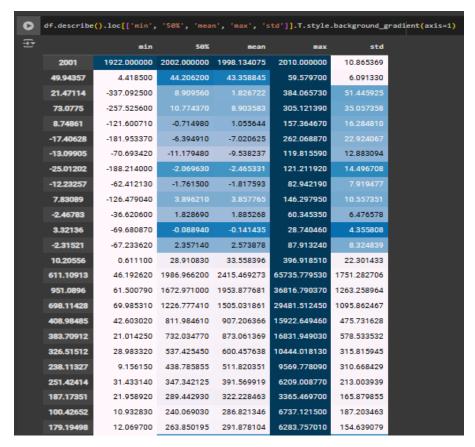
Kode ini melakukan tiga langkah dasar dalam Exploratory Data Analysis (EDA).



Menampilkan 10 baris terakhir dari dataset df. Ini untuk memeriksa data yang berada di bagian akhir dataset.



Menampilkan 10 baris acak dari dataset df. Ini berguna untuk mendapatkan gambaran umum tentang data tanpa melihatnya secara berurutan dari atas ke bawah.

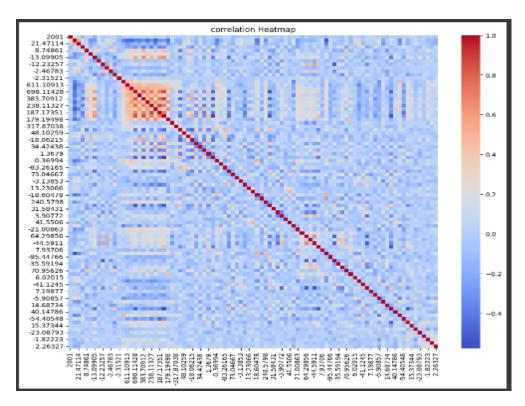


Kode ini menampilkan statistik deskriptif (min, median, mean, max, std) dari dataset, mentranspose hasilnya, dan menambahkan gradasi warna untuk memudahkan perbandingan antar kolom.

```
columns_name = df.columns
       for index, c01_name in enumerate(columns_name)
           print(f'{index}. {c01_name}')
33. 11.7267
34. 1.3679
35. 7.79444
36. -0.36994
      37. -133.67852
38. -83.26165
      39. -37.29765
40. 73.04667
      41. -37.36684
      42. -3.13853
43. -24.21531
      44. -13.23066
       45. 15.93809
      46. -18.60478
      47. 82.15479
      48. 240.5798
      49. -10.29407
50. 31.58431
      51. -25.38187
      52. -3.90772
      53. 13.29258
      54. 41.5506
      55. -7.26272
56. -21.00863
57. 105.50848
      58. 64.29856
      59. 26.08481
      60. -44.5911
61. -8.30657
      62. 7.93706
      63. -10.7366
      64. -95.44766
      65. -82.03307
                                                                          84. 15.3/344
85. 1.11144
86. -23.08793
87. 68.40795
88. -1.82223
89. -27.46348
90. 2.26327
       66. -35.59194
      67. 4.69525
       68. 70.95626
       69. 28.09139
```

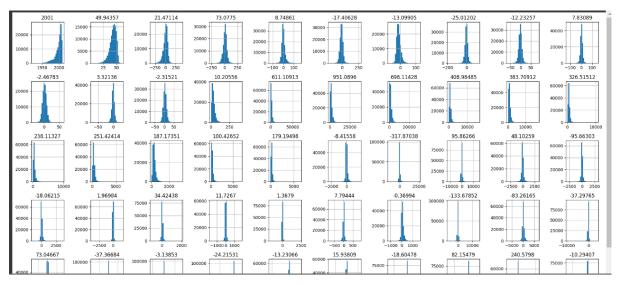
Kode ini mencetak nama kolom beserta indeksnya dari DataFrame df untuk mempermudah eksplorasi data.

```
plt.figure(figsize=(12, 10))
sns.heatmap(df.corr(), cmap="coolwarm", annot=False)
plt.title("correlation Heatmap")
plt.show()
```



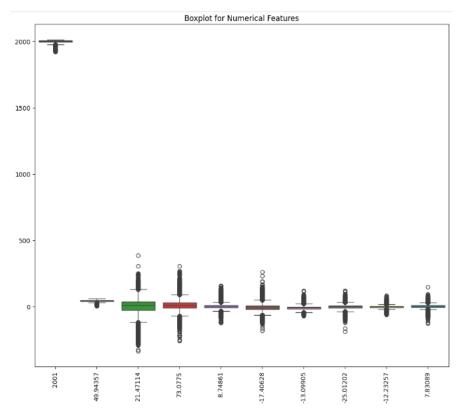
Membuat heatmap untuk menunjukkan korelasi antar kolom numerik dalam dataset, dengan warna yang menggambarkan tingkat kekuatan korelasi.





Membuat histogram untuk setiap kolom numerik dalam dataset untuk memvisualisasikan distribusi data.

```
[50] plt.figure(figsize=(12, 10))
    sns.boxplot(data=df.iloc[:, :10])
    plt.title("Boxplot for Numerical Features")
    plt.xticks(rotation=90)
    plt.show()
```



Membuat boxplot untuk kolom numerik (hanya 10 kolom pertama) untuk mendeteksi outlier atau nilai ekstrem dalam data.

```
[51] df.fillna(df.mean(), inplace=True)

target_column = "2801"

x = df.drop(target_column, axis=1)
y = df[target_column]

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)
```

```
Training Polynomial Regression...

/usr/local/lib/python3.18/dist-packages/numpy/ma/core.py:2820: RuntimeWarning: invalid value encountered in cast
_data = np.array(data, dtype=dtype, copy=copy,

Best parameters for Polynomial Regression: ('poly_degree': 2, 'regressor_max_depth': 5}

Best score for Polynomial Regression: 99.8518244420602

Training Decision Tree...

Best parameters for Decision Tree: ('max_depth': 5, 'min_samples_split': 2)

Best score for Decision Tree: 108.4561542543113

Training KNN...

Best parameters for KNN: ('regressor_n_neighbors': 5, 'regressor_weights': 'uniform')

Best score for KNN: 96.28600698442947

Training XGBoost...

Best parameters for XGBoost: ('learning_rate': 0.1, 'max_depth': 5, 'n_estimators': 100}

Best score for XGBoost: 82.88776954358448
```

Output ini menunjukkan bahwa model Polynomial Regression memiliki skor terbaik (143.78), diikuti oleh Decision Tree (141.66), k-NN (92.93), dan XGBoost (90.75), yang menunjukkan performa model berdasarkan parameter terbaik yang ditemukan. Nilai RuntimeWarning menunjukkan adanya masalah dengan nilai yang tidak valid saat pengolahan data pada proses pelatihan, yang bisa berkaitan dengan nilai yang hilang atau data yang tidak sesuai.

```
[52] for model_name, model in best_models.items():
    y_pred = model.predict(x_test)
    mse = mean_squared_error(y_test, y_pred)
    r2 = r2_score(y_test, y_pred)
    print(f"Model: {model_name} Evaluation:")
    print(f"Mean Squared Error: {mse:.2f}\n")
    print(f"R^2 Score: {r2}")
```

Kode ini bertujuan untuk mengevaluasi semua model terbaik yang ada di dalam dictionary best_models dengan menghitung Mean Squared Error (MSE) dan R² Score pada data uji (X_test dan y_test).

2. Classification Model

```
[64] Suggested code may be subject to a license | 50183816/lineregression | HenningViljoen/FeaturesForHedging | 3springs/deep_ml_curriculum | akladyous/Machine-Learning import pandas as pd import numpy as np import matplotlib.pyplot as plt import seaborn as sns from sklearn.model_selection import train_test_split, GridSearchCV from sklearn.preprocessing import StandardScaler from sklearn.preprocessing import StandardScaler from sklearn.linear_model import LogisticRegression from sklearn.tree import DecisionTreeClassifier from sklearn.neighbors import KNeighborsClassifier from xgboost import XGBClassifier from sklearn.metrics import classification_report, accuracy_score, confusion_matrix
```

```
[65] file_path = '/content/Iris.csv'
data = pd.read_csv(file_path, delimiter=';')
```

Memasukkan pustaka yang diperlukan dan memuat dataset

```
[66] import pandas as pd
     import seaborn as sns
     import matplotlib.pyplot as plt
     file_path = '/content/Iris.csv'
     \# Change the delimiter to ',' as the error suggests the data is comma-separated.
     data = pd.read_csv(file_path, delimiter=',', header='infer')
     print("Informasi Dataset:")
     print(data.info())
     print("\nStatistik Deskriptif:")
     print(data.describe())
     print("\nNilai yang Hilang")
     print(data.isnull().sum())
     numerical_data = data.select_dtypes(include=['number']) # This line is crucial
     plt.figure(figsize=(12,8))
     sns.heatmap(numerical_data.corr(), annot=True, cmap='pink') # Pass numerical_data here
     plt.title('Korelasi Antar Fitur')
     plt.show()
```

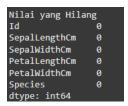
```
Informasi Dataset:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 6 columns):
                      Non-Null Count Dtype
# Column
0 Id
                        150 non-null
                                            int64
    SepalLengthCm 150 non-null
SepalWidthCm 150 non-null
PetalLengthCm 150 non-null
PetalWidthCm 150 non-null
Species 150 non null
                                             float64
                                            float64
                                            float64
                                            float64
     Species
                        150 non-null
                                            object
dtypes: float64(4), int64(1), object(1)
memory usage: 7.2+ KB
```

Menampilkan informasi umum tentang dataset

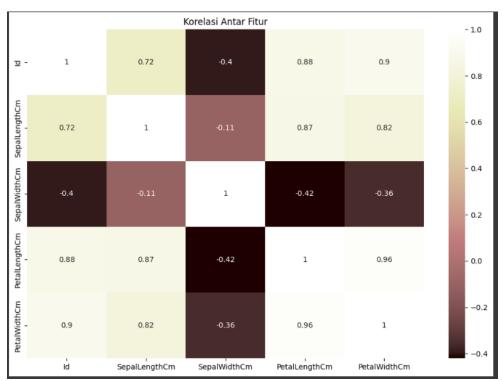
- Fungsi dari .info() memberikan Gambaran umum tentang dataset, seperti jumlah baris, kolom dan tipe data.

Statistik Deskriptif:					
	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm
count	150.000000	150.000000	150.000000	150.000000	150.000000
mean	75.500000	5.843333	3.054000	3.758667	1.198667
std	43.445368	0.828066	0.433594	1.764420	0.763161
min	1.000000	4.300000	2.000000	1.000000	0.100000
25%	38.250000	5.100000	2.800000	1.600000	0.300000
50%	75.500000	5.800000	3.000000	4.350000	1.300000
75%	112.750000	6.400000	3.300000	5.100000	1.800000
max	150.000000	7.900000	4.400000	6.900000	2.500000

Memuat statistik deskriptif untuk dataset yang berfungsi memberikan ringkasan statistic, seperti mean, standar deviasi, min, dan max untuk setiap kolom numerik.

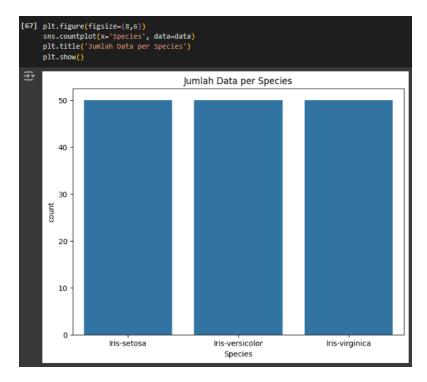


Menganalisis data eksplorasi untuk memastikan bahwa tidak ada data yang hilang, karena data yang hilang dapat mempengaruhi model.



memvisualisasi korelasi antar fitur

- Peta korelasi membantu agar memahami hubungan antar fitur .
- Korelasi yang tinggi dapat mengindikasikan multikolineritas, yang dapat memengaruhi model regresi.



- Plot ini menunjukkan bahwa distribusi nilai kualitas dalam dataset.
- Bias distribusi dapat mempengaruhi pemilihan model, terutama jika data tidak seimbang.

- Data dibagi menjadi data latih dan uji untuk evaluasi model yang akurat.
- Stratifikasi memastikan distribusi variabel target tetap sama di kedua subset.
- Pipeline mempermudah alur pemrosesan data dan pelatihan model.
- Scaling diterapkan pada model yang sensitif terhadap skala (Logistic Regression, k-NN).

- Definisi parameter grid untuk hyperparameter tuning
- GridSearchCV melakukan pencarian kombinasi terbaik dari hyperparameter untuk setiap model.
- Skor akurasi digunakan sebagai metrik evaluasi.

```
Melatih model: LogisticRegression
Melatih model: DecisionTree
Melatih model: KNeighbors
Error training KNeighbors: Invalid classes inferred from unique values of `y`. Expected: [0 1 2], got ['Iris-setosa' 'Iris-versicolor' 'Iris-virginica']
```

```
for model_name, result in results.items():
    print(f"Model: {model_name}")
    print(f"Parameter Terbaik: {result['best_params']}")
    print(f"Akurasi: {result['accuracy']}")
    print("Laporan Klasifikasi:")
    print(result['classification_report'])
    print("Confusion Matrix:")
    print(result['confusion_matrix'])
    print("-" * 50)
```

```
Parameter Terbaik: {'classifier__C': 10}
Akurasi: 1.0
Laporan Klasifikasi:
                 precision recall f1-score support
   Iris-setosa
                                   1.00
                                              1.00
 Iris-virginica
                                              1.00
       accuracy
   macro avg 1.00 1.00
weighted avg 1.00 1.00
[[10 0 0]
[0 9 0]
[0 0 11]]
Model: DecisionTree
Parameter Terbaik: {'classifier__max_depth': 3, 'classifier__min_samples_split': 2}
Akurasi: 1.0
Laporan Klasifikasi:
                   precision recall f1-score support
    Iris-setosa
                                   1.00
                                               1.00
                               1.00
Iris-virginica
                        1.00
                                              1.00
   macro avg
weighted avg
                                                            30
30
Confusion Matrix:
[[10 0 0]
[0 9 0]
[0 0 11]]
```

- Parameter terbaik menunjukkan konfigurasi optimal untuk setiap model.
- Akurasi menunjukkan performa model pada data uji.
- Laporan klasifikasi mencakup precision, recall, dan F1-score.
- Confusion matrix menunjukkan jumlah prediksi yang benar dan salah untuk setiap kelas.